

Домашнее задание 2.

Моделирование DWH и ELT-пайплайны

Задача и ожидаемый результат

Выберите предметную область, найдите источник данных и постройте небольшое хранилище для конкретного потребителя. Например, отчёт должен помогать ему сравнивать показатели по дням и выбранным категориям. Сформулируйте свой вопрос и определите, что именно считается в ответе.

Результат: работающий локальный ELT-пайплайн: исходные данные загружаются в PostgreSQL, модели и проверки описаны в dbt, запуском управляет Apache Airflow. Витрина отвечает на выбранный вопрос. Повторный расчёт на одинаковом входе сохраняет результат; при ошибке качества потребитель продолжает видеть предыдущую корректную публикацию.

Важно: Готовые данные, Docker Compose, DAG и dbt-проект для выполнения ДЗ не выдаются. Конфигурацию окружения и код решения вы создаёте сами. Способ локальной установки выбираете самостоятельно; зафиксируйте версии и порядок запуска. Ориентиры: разбор на семинаре, запись занятия и документация выбранных версий инструментов.

1. Требование и модель

- Найдите доступный источник и выберите небольшой срез, на котором ответ можно проверить вручную. Укажите происхождение данных, поля, единицы измерения и временную зону, если есть даты. Размер набора сам по себе не оценивается.
- Назовите потребителя, 1–2 вопроса к данным и первый полезный результат — MVP.
- Определите гранулярность: «Одна строка факта — это ...». Покажите схему с одним фактом, минимум двумя осмысленными измерениями и одной агрегатной витриной. Укажите ключи и кардинальность связей.
- Обоснуйте выбор размерной модели: почему она подходит этому отчёту, какие задачи потребовали бы другого подхода. Объясните, нужна ли история атрибутов и какую задачу она решает.
- Используйте поля, которые действительно есть в источнике. Если подходящих измерений не хватает, выберите другой срез или источник. Не придумывайте реальные деньги, клиентов или даты ради схемы.

2. Работающий ELT

- Воспроизводимо загрузите выбранный срез в raw. Зафиксируйте вход либо способ получения именно этого среза.
- Реализуйте в dbt staging → измерения и факт → витрину. Опишите преобразования типов, обработку повторов и выбор актуального состояния. Зависимости моделей задайте через `ref()`, внешние таблицы — через `source()`, где применимо.
- Покажите соответствие физических таблиц логическим слоям Raw / ODS / DDS / витрины. Отдельная схема базы для каждого слоя не обязательна.
- Выполните 2–3 SQL-запроса к результату. Для каждого приведите вопрос, ожидаемое значение на контрольном срезе и наблюдение. Хотя бы один итог проверьте вручную либо независимым расчётом по источнику.

- Создайте DAG Airflow: приём данных → расчёт → проверки → публикация. Связанные стадии можно объединить в задачу, объяснив, что видно в графе, а что в логе.
- Явно задайте обрабатываемый интервал или срез. Ручной запуск допустим; объясните, какой день обрабатывался бы при ежедневном расписании. Дата запуска не должна незаметно заменять дату события.
- Объясните роли инструментов и почему выбранный путь данных относится к ELT. База выполняет SQL; dbt описывает преобразования и проверки; Airflow управляет запуском.

3. Четыре диагностических случая

Подготовьте маленькие контролируемые изменения входа для своей модели. До каждого опыта верните корректное исходное состояние и получите успешную публикацию. Сценарии проверяются независимо друг от друга.

Случай	Что изменить	Что нужно доказать
Дубликат	Повторно передать одну запись источника	Лишний факт не возникает; ключи и меры сохраняются
Пересечение истории	Сделать две версии одного атрибута действующими на дату события	Проверка обнаруживает неоднозначность; ошибочная публикация блокируется
Позднее исправление	Изменить значение уже обработанного события, сохранив его бизнес-дату	Меняется нужный прошлый результат; повтор не удваивает исправление
Второй источник	Добавить другую сущность с таким же локальным ID из другого источника	Сущности не сливаются; источник учитывается в идентификации

Если исходный набор не содержит истории или второго источника, подготовьте небольшой **явно помеченный синтетический тестовый вход** для соответствующего случая. Он должен проверять вашу модель или отдельную минимальную модель вашего домена. Объясните принятые допущения; не представляйте тестовые записи как реальные данные источника. Это не требует строить универсальную систему интеграции или промышленный механизм SCD2.

Для каждого случая приведите: **изменённые строки** → **прогноз** → **наблюдение** → **объяснение** → **подтверждение кодом и результатом запроса**. Числа должны следовать из ваших данных; повторять значения учебного примера такси не требуется.

4. Качество, повтор и публикация

Добавьте проверки заполненности и уникальности ключа, хотя бы одной связи факт → измерение, допустимых значений и одного бизнес-правила. SQL-тест бизнес-правила должен возвращать нарушившие строки. Для модели с историей проверьте отсутствие пересечений интервалов и единственность версии для события.

Покажите успешный запуск, затем запуск с намеренно испорченным входом. Найдите конкретную ошибочную строку, объясните причину и восстановите корректный расчёт. Кандидат и опубликованный результат должны быть разделены: ошибка теста сама по себе не откатывает все таблицы dbt.

Дважды запустите процесс на одинаковом исправном входе и сравните ключи, строки и меры, а не только `count(*)`. Объясните, как исключаются конфликтующие параллельные запуски; для учебного решения достаточно сериализации. Назовите хотя бы одно ограничение своих проверок: например, уникальность ключа не доказывает полноту выгрузки.

Что сдать

1. **Код:** конфигурация локального окружения, загрузчик, dbt-проект с моделями и тестами, DAG Airflow.
2. **README:** источник и контрольный срез, требование, схема, гранулярность, решение по истории, версии инструментов и команды запуска с нуля.
3. **Краткий отчёт:** результаты SQL, независимый контроль, таблица четырёх случаев, сравнение повторов и ограничения решения.
4. **Скриншоты выполнения:** успешный DAG; задача с ошибкой качества и диагностикой; результат витрины; сохранённая публикация после ошибки. Подпишите, какой вывод подтверждает каждый снимок. Результаты ключевых SQL-запросов и команды приложите также текстом.
5. **Входные данные:** небольшой воспроизводимый срез и тестовые изменения либо точный способ их получения. Не включайте приватные данные, секреты, контейнерные тома и полные каталоги логов.

Оценка: 10 баллов

Баллы начисляются за выполненные и подтверждённые пункты. Скриншоты сопровождают код и выводы, но не заменяют их. Оценивание выполняется по этой рубрике; правила использования инструментов и академической добросовестности — по действующим объявлениям курса.

Область	Баллы	За что начисляются
Модель	3	1 — требование и гранулярность; 1 — схема, ключи и связь с источником; 1 — обоснование моделирования и истории
Реализация ELT	3	1 — воспроизводимая загрузка и staging; 1 — рабочие измерения, факт и витрина; 1 — осмысленные запросы и независимый контроль
Диагностика и повтор	2	1 — четыре случая с прогнозом, наблюдением и объяснением; 1 — работающие проверки, найденная ошибка и стабильный повтор
DAG и публикация	2	1 — рабочий DAG с явным срезом и объяснением ролей; 1 — подтверждённая блокировка ошибочной публикации и восстановление

Если возникли вопросы

Пишите преподавателю в чат или личные сообщения: вопросы по выбору данных, модели и запуску приветствуются. Приложите цель шага, версии инструментов, команду или небольшой фрагмент кода, полный текст ошибки и то, что уже проверили. Не отправляйте пароли и токены.